

# Machine Learning – Time Series


# Time Series Analítica

# ¿Qué es un Time Series?

Conjunto de observaciones ordenadas en el tiempo, a través de intervalos de tiempo regulares.

El intervalo de tiempo podría ser:

- Anual (presupuesto anual)
- Trimestral (gastos)
- Mensual (tráfico aéreo)
- Semanal (ventas semanales)
- Diario (tiempo)
- Horario (precio stocks)
- Minutos (entradas en un call center)
- Segundos (Tráfico web)



# Algunos ejemplos

a) Precio acciones Google

b) Diferencia diaria de precio acciones de Google

c) N° Strikes anuales en EEUU

d) Ventas mensuales de casas unifamiliares en EEUU

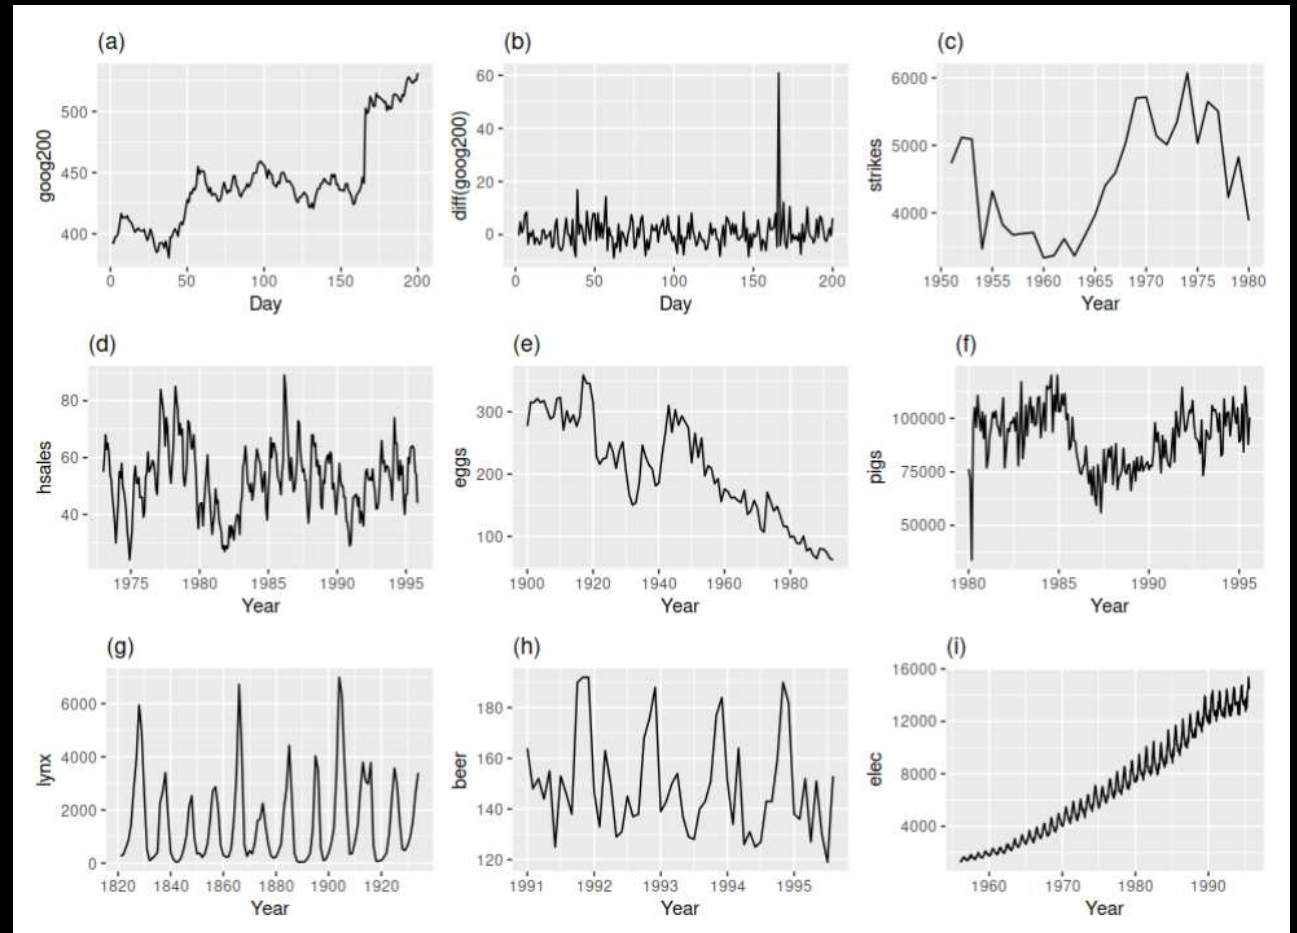
e) Precio anual de la docena de huevos en EEUU

f) Cerdos sacrificados mensualmente en Victoria, Australia

g) Total de lince atrapados en el río McKenzie (Canadá)

h) Producción cervezera mensual en Australia


i) Producción eléctrica mensual en Australia.




# Clasificación Series Temporales

Cantidad de variables

Univariante

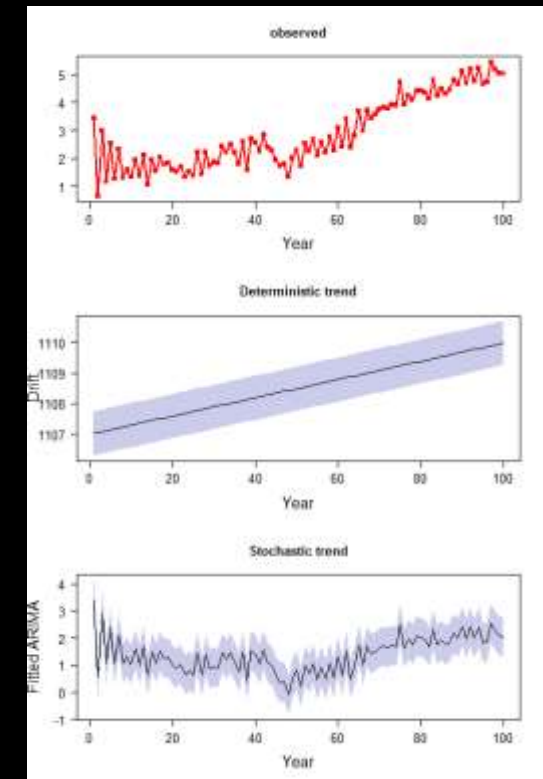


Multivariante




Tipo de Predicción

Determinística vs Estocástica




Tipo de Dato

Time Series



Cross-Section




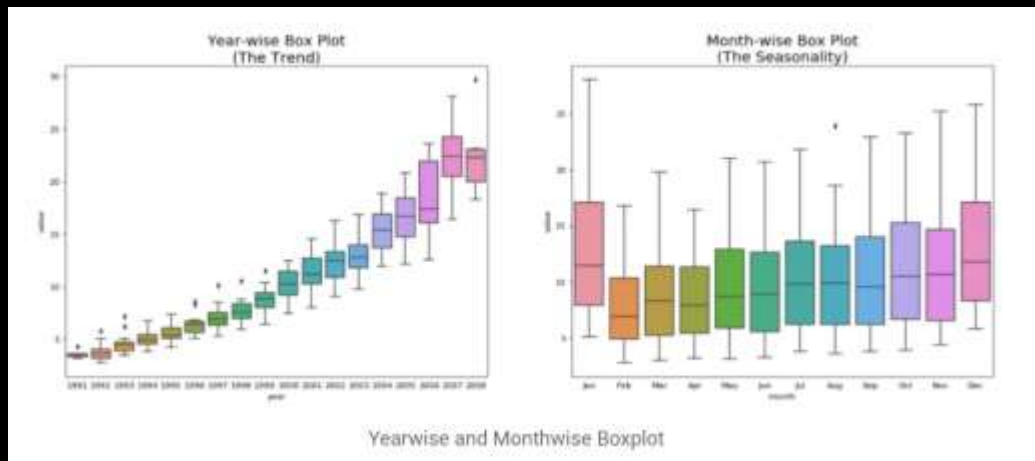

Panel

Panel Data A		Panel Data B				
Name	Year	Name	Year	Income	Age	Sex
Allen	2016	Malissa	2016	42688	27	Female
Allen	2017	Malissa	2017	21219	25	Female
Allen	2018	Malissa	2018	21219	23	Female

## Objetivo de Time Series

Entender el pasado mediante análisis  
prescriptivo para predecir el futuro

# Visualización Time Series




# Visualización Time Series

Si tenemos muchas irregularidades en la serie temporal, podemos aplicar varias técnicas para la mejora de la visualización


## Rolling

```
df[["F10.7", "R"]].rolling(24*365).median().plot(figsize=(15,4))
```

[Copy contents](#)


## Resample

```
df[["F10.7", "R"]].resample("1y").median().plot(figsize=(15,4))
```

[Copy contents](#)

## Differenciating

```
df[["F10.7", "R"]].resample("3y").median().diff().plot(subplots=True, figsize=(15,4))
```

[Copy contents](#)




# Componentes de un Time Series

**Tendency:** cambio a largo plazo en relación al nivel medio, o el cambio a largo plazo de la media.

**Seasonality:** las series presentan cierta periodicidad (mensual, anual...). Por ejemplo, el paro suele aumentar en invierno, y disminuir en verano.

**Random/Residuals:** si eliminamos los dos componentes anteriores, nos queda la componente aleatoria. Se pretende estudiar qué tipo de comportamiento aleatorio presentan estos residuos.

**Cyclic variations:** fluctuaciones producidas a lo largo de una larga tendencia. Es poco frecuente. Por ejemplo ciclos económicos de la bolsa



# Additive vs Multiplicative Decompose

**Trend:**  $T(t)$

**Seasonality:**  $S(t)$

**Cyclic variation:**  $c(t)$


**Residuals:**  $e(t)$

**Additive decompose**

$$Y(t) = T(t) + S(t) + c(t) + e(t)$$

**Multiplicative decompose**

$$Y(t) = T(t) * S(t) * c(t) * e(t)$$




Smoothing

# Smoothing

Método estadístico con el que creamos una función de aproximación para eliminar irregularidades en los datos, con el objetivo de obtener patrones significativos.

Se utiliza en modelos de predicción a corto plazo, para datos que no tienen una variación grande a lo largo del tiempo.



# Modelos de smoothing

# Simple Exponential Smoothing (SES)

Se emplea sobre datos que no tienen una tendencia o estacionalidad muy clara. Se compone de un parámetro llamado alpha (0-1), que determina cuánto suaviza la serie temporal.

$$L_t = \alpha Y_t + (1-\alpha) L_{t-1}$$

Siendo L el nivel calculado por SES, e Y el de la propia serie temporal. Cuanto mayor es alpha, más se asemeja a la serie original.

$$\begin{aligned} L_t &= \alpha Y_t + (1-\alpha) [\alpha Y_{t-1} + (1-\alpha) L_{t-2}] = \\ &= \alpha Y_t + \alpha(1-\alpha) Y_{t-1} + (1-\alpha)^2 L_{t-2} = \dots \\ &= \alpha Y_t + \alpha(1-\alpha) Y_{t-1} + \alpha(1-\alpha)^2 Y_{t-2} + \dots \end{aligned}$$

$\alpha$	$\alpha (1-\alpha)$	$\alpha (1-\alpha)^2$	$\alpha (1-\alpha)^3$
0.9	0.089	0.0089	0.00089
0.5	0.25	0.125	0.0625
0.1	0.09	0.081	0.0729

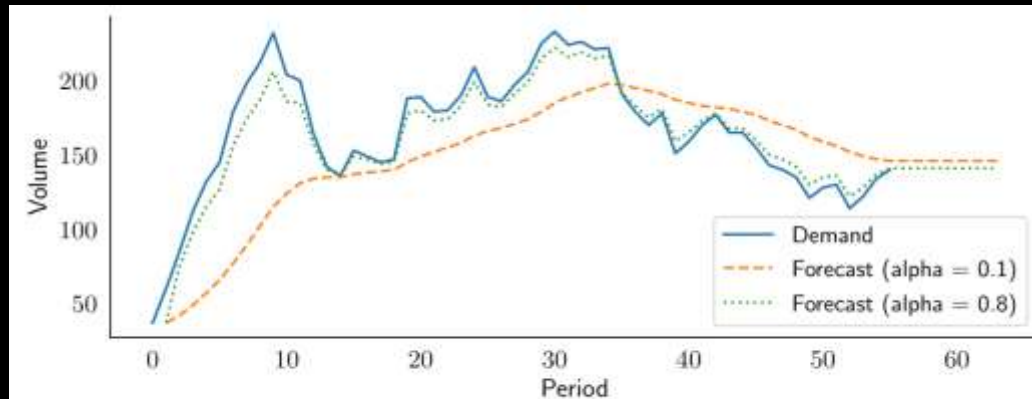


Figure 3.2: Simple smoothing

# Double Exponential Smoothing (DES)

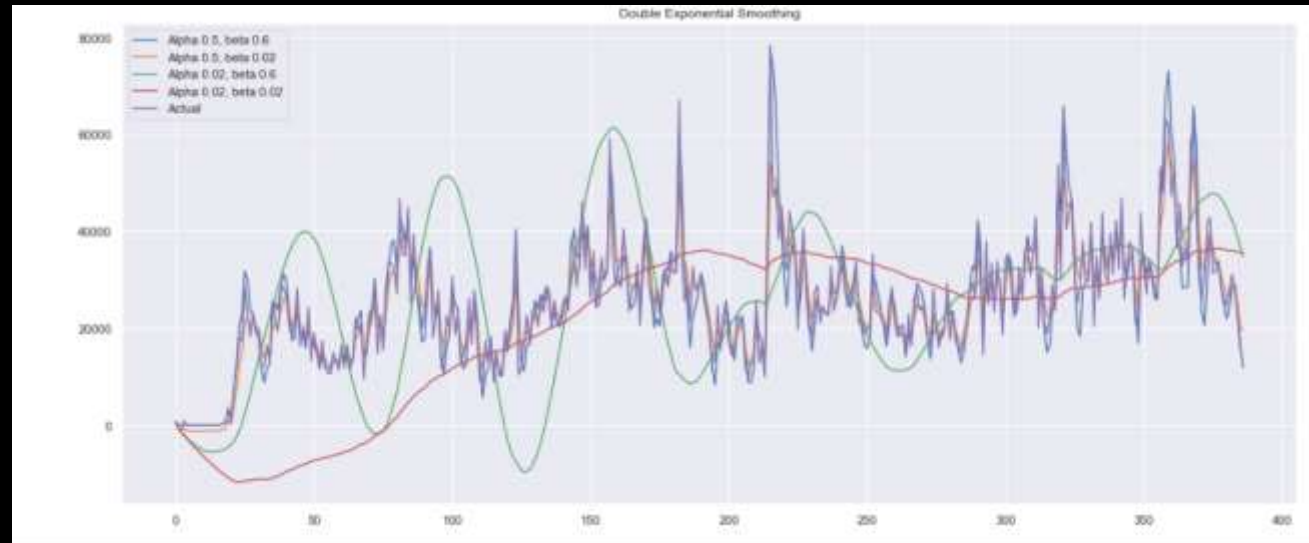
Simple Exponential Smoothing no funciona muy bien con tendencias en los Time Series. Double Exponential Smoothing maneja mejor datos con tendencia y sin seasonality, en comparación con otros métodos. Ahora, además de depender de alpha, dependerá también de beta.

$$L_t = \alpha Y_t + (1-\alpha) (L_{t-1} + T_{t-1})$$

$$F_{t+k} = L_t + KT_t$$

$$T_t = \beta (L_t - L_{t-1}) + (1-\beta) T_{t-1}$$

K es el numero de puntos a predecir



# Triple Exponential Smoothing (TES)

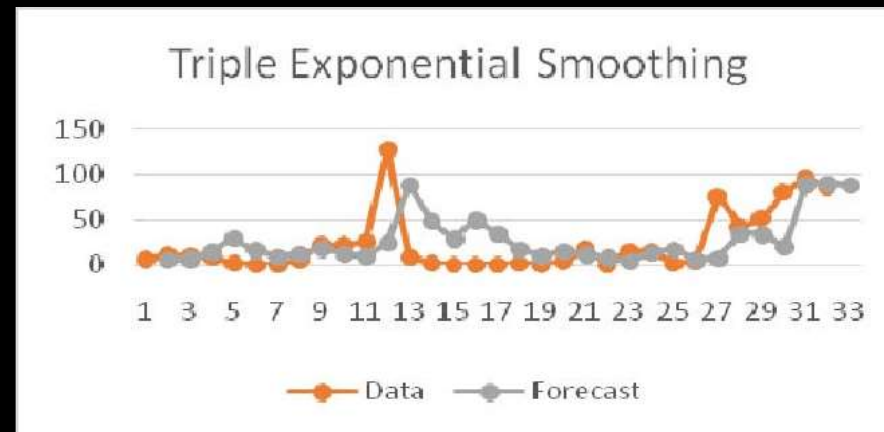
Solo nos falta un componente de los Time Series que no hemos podido modelar bien, y es seasonality. Triple Exponential Smoothing incluye un parámetro para poder modelar la periodicidad de los datos a lo largo del tiempo.

$$F_{t+k} = l_t + kT_t + S_{t+k-M}$$

$$\text{Level: } L_t = \alpha (y_t / S_{t-M}) + (1 - \alpha) (L_{t-1} + T_{t-1})$$

$$\text{Trend: } T_t = \beta (L_t - L_{t-1}) + (1 - \beta) T_{t-1}$$

$$\text{Seasonality: } S_t = \gamma (Y_t / L_t) + (1 + \gamma) S_{t-M}$$





# Stationary & Correlation

# Stationary


Una serie es stationary (estacionaria) cuando sus propiedades estadísticas no varían con el tiempo.

Una serie NO es estacionaria cuando su tendencia cambia con el tiempo, su varianza, o tiene seasonality (patrones periódicos).

## ¿Por qué es importante este concepto?



La mayoría de modelos trabajan con series estacionarias. Hay que convertirlas para poder modelar los datos. Tendrán una media, varianza y autocorrelación constantes y podremos aplicar la mayoría de conceptos estadísticos.

Las técnicas autoregresivas son modelos lineales que dependen de instantes anteriores del Time Series. Necesitamos que las features sean independientes y no estén correlacionadas unas con otras. Por eso quitamos la seasonality, para que no exista correlación alta. Las features tienen que ser totalmente independientes.



# Autocorrelation plot

- Gráfica que mide la correlación de un instante vs sus instantes anteriores.
- La autocorrelación va de -1 a 1
- Es habitual que cada instante tenga correlación alta con los mas próximos y baja con los mas lejanos



# Test de hipótesis

Una hipótesis es una pregunta que acepta si/no como respuesta.

- $H_0$ : hipótesis nula
- $H_1$ : hipótesis alternativa

¿El salario medio de España es igual que el europeo?

- $H_0$ : El salario medio España = Salario medio europeo
- $H_1$ : El salario medio España  $\neq$  Salario medio europeo

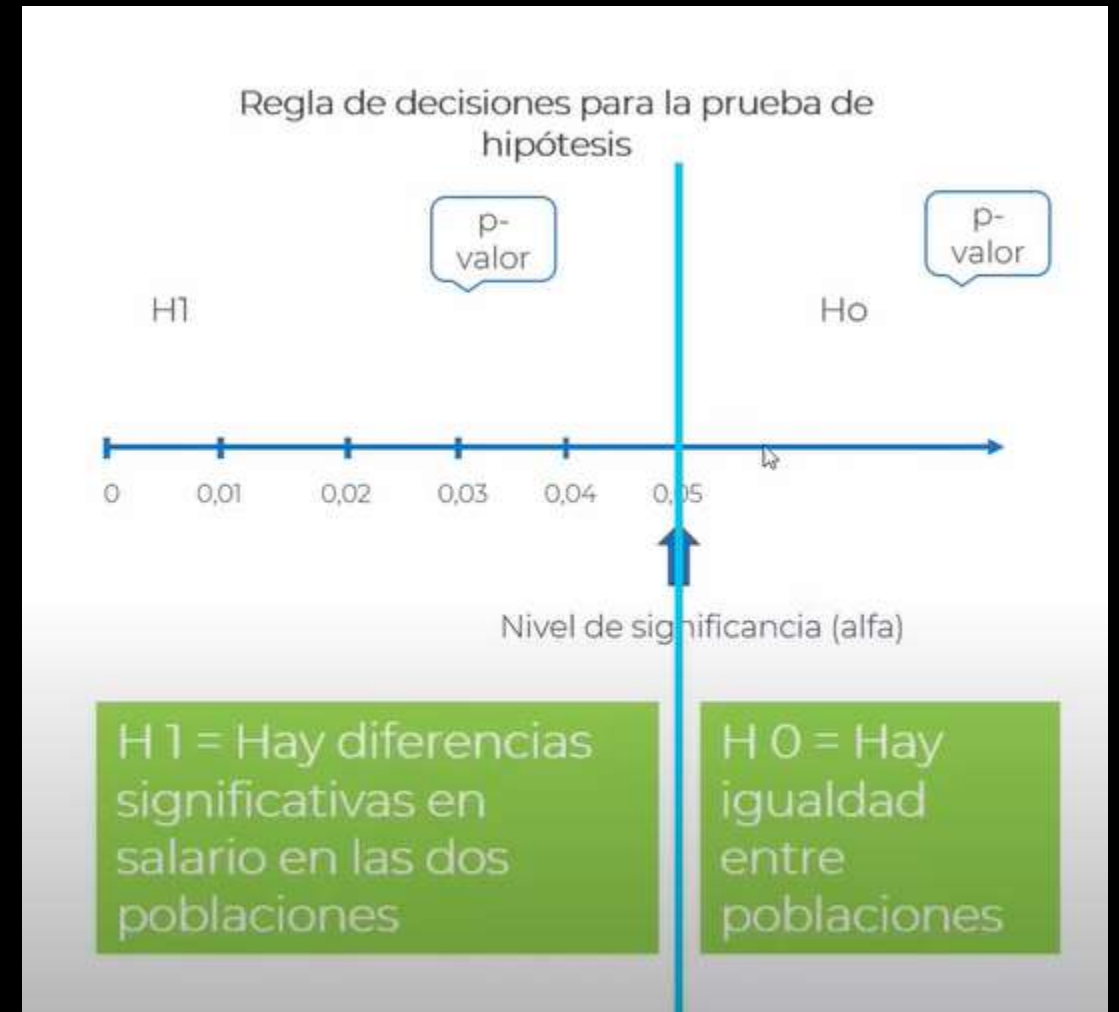
Los valores p evalúan qué tan bien los datos de la muestra apoyan el argumento de que la hipótesis nula es verdadera.

Valores p altos: los datos son probables con una hipótesis nula verdadera.

Valores p bajos: los datos son poco probables con una hipótesis nula verdadera.

$p\text{-valor} < \alpha = 0,05 \rightarrow$  Aceptas la  $H_1$

$p\text{-valor} \geq \alpha = 0,05 \rightarrow$  "Aceptas la  $H_0$ "



# ¿Cómo compruebo si una serie es Stationary?

1. **Representando la serie:** que no crezca/decrezca, tenga una tendencia constante.
2. **Seasonality:** se comprueba fácilmente de manera gráfica
3. **Estadísticos:** divide el Time Series en varias ventanas y calcula los estadísticos para cada ventana.
4. **Unit Root Tests:** se plantea la hipótesis nula de que los estadísticos no son constantes en el tiempo. El objetivo es rechazar la hipótesis nula. Rechazaremos la hipótesis nula si su p-value es inferior a su nivel de significación (0.05).
  - a. **Augmented Dickey Fuller test (ADH Test)**
  - b. Kwiatkowski-Phillips-Schmidt-Shin – KPSS test: tendencia
  - c. Philips Perron test

# ¿Qué hago para hacerla Stationary?

1. **Seasonality:** habrá que quitar la componente estacional. Diferenciando (siguiente diapo) o utilizando un SARIMA, que tiene en cuenta la seasonality.
2. **Tendencia:** hay que quitarla. Puede servir restar la media del TS, restar la componente de la tendencia del modelo aditivo o diferenciar con un lag
3. **Autocorrelación:** diferenciar primero por un lag y luego de nuevo si es necesario para eliminar la autocorrelación.


# ¿Cómo compruebo que el TS es seasonal?

1. **Plot:** lo más probable es que con un simple plot, veamos los patrones repetidos en la serie temporal

1. **Auto Correlation Function (ACF):** Cuánto de correlacionados están los valores con instantes anteriores.

La correlación lineal nos da un indicador de cuánto se relaciona linealmente una variable con otra. La autocorrelación sirve para ver si hay relación entre cada instante y sus lags, es decir, instantes anteriores.

Si existe una estacionalidad mensual, habrá correlación entre cada instante y su valor 12 instantes más atrás. 24 instantes más atrás también estará relacionado, pero no tanto.




# Deseasonalize

**Moving Average:** aplicar moving average sobre la ventana estacional (media de time series para cada ventana)


**Seasonal difference:** resta de  $Y(t) - Y(t-s)$ , siendo  $s$  el periodo estacional: 12 (meses), 4 (semanas)...

**Restar Seasonal component:** descomponer la serie mediante un modelo aditivo, y restarle la componente de seasonality a la serie.

**SARIMA:** usar un modelo que integre automáticamente este componente



# Missings



## Missings en los valores

1. **Backward fill:** lo más probable es que con un simple plot, veamos los patrones repetidos en la serie temporal
2. **Forward fill:** Cuánto de correlacionados están los valores con instantes anteriores.
3. **Interpolate:** interpolar valores en función del anterior y posterior. Se suele usar la media.
4. **KNN:** similitud con los n últimos valores de la serie.
5. Linear interpolation
6. Quadratic/Cubic interpolation

## Missings en las fechas

Podría ocurrir que falte alguna fecha. Se podría solucionar obteniendo un range desde el primer valor al último, equiespaciándolo como nuestros datos (diario, horario...), y a este vector le aplicamos un left join de la serie original. Obtendremos como resultado un TS sin huecos en el tiempo y con algunos missings en los valores, que habrá que rellenar con las técnicas anteriores.



# Time Series

## Técnicas de Regresión

## Auto Regressive (AR)

Modelo que predice valores futuros basados en los datos pasados. Para utilizar un modelo AR necesitamos un TS stationary.

En la fórmula beta es un parámetro que podremos ir modificando, de -1 a 1, y epsilon es ruido.

**p** es el orden del modelo de autoregresión. Se suele usar 1 o 2.

Alpha es el intercept.

$$Y_t = \alpha + \beta_1 Y_{t-1} + \beta_2 Y_{t-2} + \dots + \beta_p Y_{t-p} + \epsilon_t$$

## Moving Average (MA)

Básicamente el MA predice valores futuros utilizando los errores cometidos en el pasado. También necesitamos un TS stationary.

**q** es el orden del modelo MA.

$$Y_t = \alpha + \epsilon_t + \phi_1 \epsilon_{t-1} + \phi_2 \epsilon_{t-2} + \dots + \phi_q \epsilon_{t-q}$$

# ARIMA

## AutoRegressive Integrated Moving Average

Modelo que utiliza valores y errores pasados para realizar predicciones en una serie temporal.

## Seasonality

La serie temporal NO puede tener seasonality. ARIMA lo modelará con el parámetro d. O diferencio por el lag de su seasonality o utilizo SARIMA.

## ¿Por qué no puede tener seasonality?

Este modelo es una REGRESIÓN basada en instantes anteriores, por lo que no puede existir correlación alta entre instantes de la serie temporal. Seasonality implica repetición de patrones cada X periodo (12 meses, 24h...), por lo que NO podemos usar datos con seasonality. Necesitamos garantizar la independencia de los lags de la serie.

## SARIMA

Podemos utilizar el modelo SARIMA para series temporales con seasonality.

## Stationary

El TS tiene que ser stationary. Lo haremos con el parámetro d

p d q

**Auto Regressive (AR)**

*Cantidad de lags usados  
como predictores*

**Integrated (I)**

*Número de veces que hay  
que diferenciar el TS*

**Moving Average (MA)**

*Cantidad de errores  
utilizados en la predicción*

## ¿Cómo consigo un TS stationary?

Diferenciándolo una o dos veces. Restando cada valor por su anterior.

Esto sería el parámetro “d” de ARIMA. Si la serie ya es stationary, d=0.

## ¿Cómo elimino la seasonality?

Diferenciándolo por el periodo de la estacionalidad. Por ejemplo, diferenciando de 12 en 12, si tenemos datos mensuales.

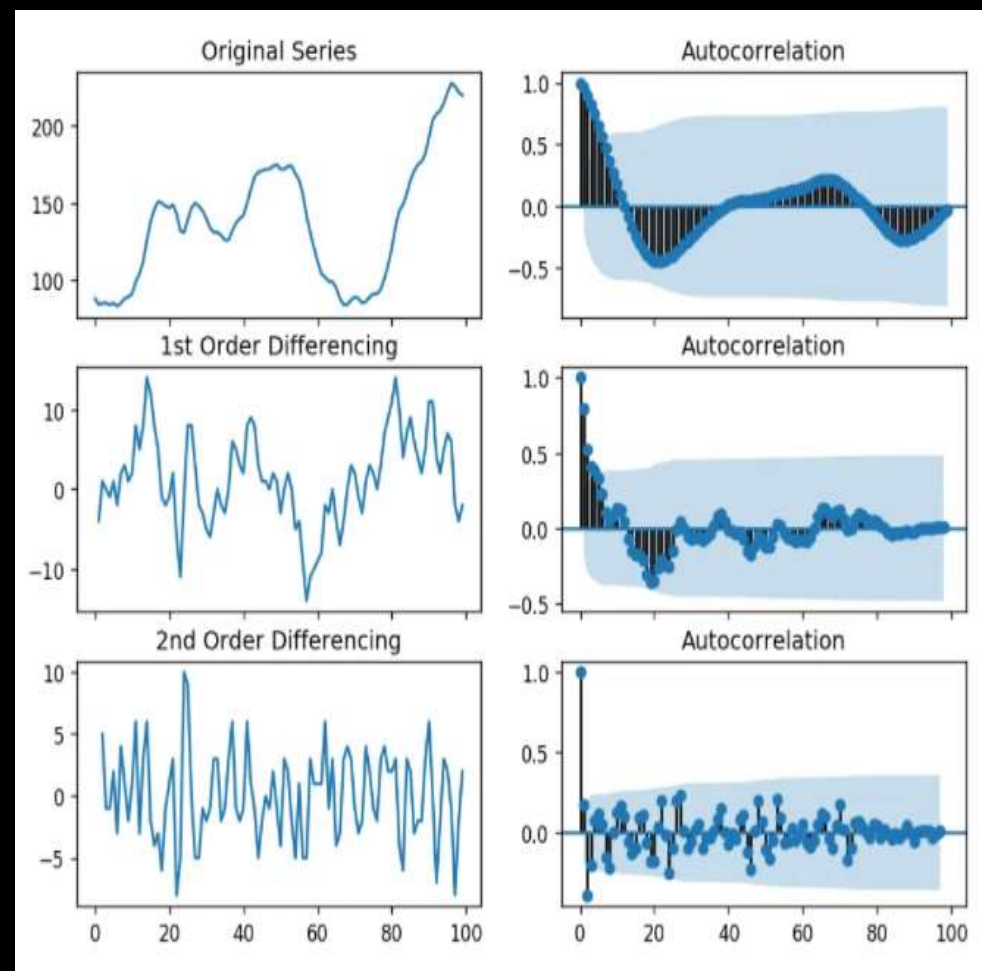


O usando un SARIMA

# Valor differencing (d)

**¿Para qué diferenciamos?** Para convertir un non-stationary TS en un stationary. Por tanto, primero habrá que comprobar que efectivamente el TS es stationary. Para ello podemos aplicar el **test Augmented Dickey Fuller**.


Para obtener el valor óptimo de diferenciación hay que fijarse en la ACF (Autocorrelation Function). Buscamos que los lags no tengan autocorrelación. Posibles escenarios:

1. A partir de cierto lag, tiene una caída brusca en correlación: diferenciaremos por ese lag
2. Una caída exponencial: sería una buena situación. Diferenciaremos por el lag 1
3. 10 lags o más con autocorrelación alta: tiene pinta de que tendremos que diferenciar dos veces.



# SARIMA

Modelo ARIMA que permite modelizar los comportamientos de seasonalidad, es decir, patrones repetitivos en los datos



# SARIMAX

Añadimos una variable exógena, que básicamente es una variable externa

# Otros modelos

Podemos transformar la serie temporal en un conjunto de lags, que serían las features del modelo, e intentaríamos predecir como si fuese un modelo clásico supervisado de regresión.

En este caso podríamos aplicar otros algoritmos: DecisionTreeRegressor, RandomForestRegressor...

	data	t-12	t-11	t-10	t-9	t-8	t-7	t-6	t-5	t-4	t-3	t-2	t-1
date													
1963-01-01	0.83	0.710000	0.630000	0.850000	0.440000	0.610000	0.69	0.92	0.55	0.72	0.77	0.92	0.60
1963-04-02	0.80	0.630000	0.850000	0.440000	0.610000	0.690000	0.92	0.55	0.72	0.77	0.92	0.60	0.83
1963-07-02	1.00	0.850000	0.440000	0.610000	0.690000	0.920000	0.55	0.72	0.77	0.92	0.60	0.83	0.80
1963-10-01	0.77	0.440000	0.610000	0.690000	0.920000	0.550000	0.72	0.77	0.92	0.60	0.83	0.80	1.00
1964-01-01	0.92	0.610000	0.690000	0.920000	0.550000	0.720000	0.77	0.92	0.60	0.83	0.80	1.00	0.77
...													
1979-10-01	9.99	6.840000	9.540000	10.260000	9.540000	8.729999	11.88	12.06	12.15	8.91	14.04	12.96	14.85
1980-01-01	16.20	9.540000	10.260000	9.540000	8.729999	11.880000	12.06	12.15	8.91	14.04	12.96	14.85	9.99
1980-04-01	14.67	10.260000	9.540000	8.729999	11.880000	12.060000	12.15	8.91	14.04	12.96	14.85	9.99	16.20
1980-07-02	16.02	9.540000	8.729999	11.880000	12.060000	12.150000	8.91	14.04	12.96	14.85	9.99	16.20	14.67
1980-10-01	11.61	8.729999	11.880000	12.060000	12.150000	8.910000	14.04	12.96	14.85	9.99	16.20	14.67	16.02

# Facebook Prophet

Librería open source de Facebook que permite realizar forecast de series temporales

```
pip install fbprophet
```

The logo for Facebook Prophet, featuring the word "PROPHET" in a bold, white, sans-serif font. The letter "O" is replaced by a blue circular icon with a white dot in the center, and a small blue dot is positioned above it, resembling a stylized eye or a data point.